# Персонализированная рекомендательная система новых категорий для CRM-коммуникаций

*Personalized Recommendation of New Categories for CRM Communications*

Студентка: Рощина Полина Александровна

Образовательная программа «Машинное обучение и анализ данных»

## 1. Введение

### 1.1. Актуальность и практический контекст

Современные классифайд-платформы накапливают подробную историю поведения пользователей: просмотры объявлений, добавления в избранное и контакты с исполнителями или продавцами. Эти события отражают не только уже сформированный спрос, но и изменение потребностей пользователя во времени. Поэтому поведенческие данные могут использоваться для построения персонализированных рекомендаций, которые помогают пользователю находить релевантные направления внутри большого и неоднородного каталога.

Для раздела «Услуги» такая задача особенно важна. Потребность в услуге нередко возникает как продолжение другого пользовательского сценария: после выбора или покупки товара могут потребоваться доставка, установка, ремонт или обслуживание, а интерес к поездке или мероприятию может быть связан с поиском сопутствующих услуг. CRM-коммуникации позволяют познакомить пользователя с такими направлениями, однако их эффективность зависит от того, насколько точно выбраны категория и аудитория коммуникации.

По внутреннему исследованию, с 2023 года доля внешних пользователей среди новых покупателей и исполнителей «Услуг» снижается. Основным источником новой аудитории остаются переходы из других разделов Авито, однако заметного роста этих переходов в рассматриваемом периоде не наблюдалось [14]. Это мотивирует персонализированный отбор новых категорий.

Ранее для поиска перспективных направлений использовался подход на основе агрегированных переходов между категориями. Он позволяет выявлять пары A → B, которые часто последовательно встречаются в поведении пользователей, и тем самым формировать гипотезы для CRM-кампаний. При этом такой подход описывает среднюю закономерность на уровне группы и не оценивает, насколько категория B релевантна конкретному пользователю из категории A. В результате одна и та же коммуникация может направляться широкой аудитории с существенно различающимися потребностями.

Задача работы состоит в том, чтобы по последовательности действий оценить, какие новые категории могут заинтересовать конкретного пользователя. Для каждой пары «пользователь — категория» модель вычисляет относительную оценку релевантности и формирует ранжированный список. Эта оценка задаёт порядок кандидатов, но не является вероятностью будущего контакта или эффекта CRM-сообщения. Модель должна учитывать тип действия, порядок и давность событий, структуру каталога и несколько разных направлений поведения.

Полученные оценки релевантности могут применяться в двух взаимосвязанных сценариях. В первом случае для пользователя выбираются наиболее подходящие новые категории. Во втором случае для заданной категории ранжируются пользователи и формируется наиболее релевантная аудитория CRM-коммуникации. Таким образом, одна модель может поддерживать как персонализированные рекомендации, так и адресный отбор аудитории под конкретное направление кампании.

## 1.2. Цель и задачи исследования

Целью работы является разработка и исследование персонализированной рекомендательной системы, которая по истории поведения пользователя формирует ранжированный список новых категорий, релевантных его будущему интересу, и позволяет использовать полученные оценки для адресного отбора аудитории CRM-коммуникаций.

Объектом исследования является последовательное поведение пользователей классифайд-платформы, представленное событиями взаимодействия с объявлениями и категориями каталога. Предмет исследования — методы персонализированного ранжирования новых категорий на основе разнородных поведенческих событий, их временного порядка и иерархической структуры каталога.

Для достижения поставленной цели необходимо решить следующие задачи:

1. проанализировать существующие подходы к последовательным рекомендательным системам и моделям с несколькими представлениями пользователя и определить их применимость к задаче рекомендации новых категорий;
2. формализовать обучающую задачу на уровне пары «пользователь — категория», включая правило новизны категории, способ построения целевой переменной и допустимое множество рекомендаций;
3. разработать представление пользовательской истории, учитывающее тип действия, время события и полный путь категории в иерархии каталога;

4. выбрать содержательные базовые методы и разработать основную модель, способную учитывать несколько разных направлений поведения пользователя;
5. построить временной протокол обучения и валидации, исключающий использование будущей информации, и определить метрики качества ранжирования;
6. провести контролируемое сравнение одного и двух скрытых представлений пользователя, а также отдельные проверки влияния объёма данных, длины истории и временного переноса;
7. разработать процедуру применения модели для персонализированных рекомендаций и формирования аудитории под заданную категорию, а также определить ограничения практического использования.

### 1.3. Исследовательские вопросы и вклад работы

Исследование отвечает на четыре вопроса. Превосходит ли последовательная персонализированная модель воспроизводимые базовые методы на одной аудитории? Помогают ли два скрытых представления пользователя по сравнению с одним? Как меняется качество при увеличении объёма обучения и размерности модели? Можно ли использовать одни и те же оценки и для рекомендации категорий, и для формирования CRM-аудитории?

Основное сравнение проводится на единой аудитории из 100 000 пользователей: для всех методов совпадают целевые категории и маски допустимых кандидатов. Полная модель d=128 обучена на всём подготовленном пуле, а контролируемые архитектурные проверки выполняются отдельно на d=64. Значения разных серий не объединяются в одну кривую. Признаки действия и времени входят в основную конфигурацию, но их самостоятельный вклад отдельно не оценивается.

Работа адаптирует идею ComiRec-SA к рекомендации новых категорий и объединяет два прикладных сценария. На единой аудитории из 100 000 пользователей полная модель d=128 получила Recall@5 = 0,4046 против 0,3074 у PureSVD и 0,1685 у 30-дневной офлайн-адаптации модели переходов. Разность с PureSVD статистически значима при $\alpha = 0{,}05$. Полная d=128 также значимо превысила d=64 на той же аудитории. В CRM-кампании с персонализированным отбором выросли целевые контакты и покупатели, однако кампании не являлись прямым сравнением алгоритмов.

# 2. Постановка задачи

## 2.1. От агрегированных переходов к персонализированному ранжированию

В исходном подходе единицей анализа является направленная пара категорий A → B. Статистическая связь между категориями полезна для генерации гипотез: если действия в A часто предшествуют действиям в B, категорию B можно рассматривать как потенциальное направление коммуникации. Однако значение такой связи одинаково для всех пользователей исходной категории и не учитывает индивидуальную историю каждого человека.

В новой постановке единицей прогнозирования становится пара «пользователь — детальная категория». Модель получает историю, доступную к моменту T, и оценивает каждую допустимую категорию. Результатом служит индивидуальный ранжированный список рекомендаций. Поскольку в следующие 14 дней пользователь может обратиться сразу в несколько новых категорий, один пример может иметь несколько правильных ответов.

### 2.2. Уровень таксономии

Каталог имеет иерархическую структуру: вертикаль, категория и нижний уровень. В работе детальная категория задаётся полным путём vertical | category | param1. Полный путь нужен, потому что одинаковое название нижнего уровня в разных ветках каталога может обозначать разные потребности. Такие категории получают разные идентификаторы и не объединяются при подготовке данных, обучении или применении модели.

Обозначим множество детальных категорий через L, а конкретную категорию через l = (v, c, p), где v — вертикаль, c — категория, p — нижний уровень в контексте полного пути. Более крупные уровни таксономии используются как контекст и могут быть получены агрегацией, но не заменяют основную целевую переменную.

### 2.3. Обучающий пример и целевая переменная

Один обучающий пример задаётся пользователем u и моментом времени T. Во вход модели попадают только события, произошедшие до T. Основное историческое окно составляет 90 дней, а целевое окно — 14 дней после T. Эти значения фиксируют бизнес-сценарий: модель использует недавнее поведение и прогнозирует интерес на горизонте, сопоставимом с периодом CRM-кампании.

$$H(u,T) = \{e_i : T - 90 \text{ дней} \le t_i < T\}$$

Категория считается новой, если в течение 90 дней до T пользователь не совершал в ней контакт. Просмотры и добавления в избранное не делают категорию известной: они

остаются сигналами интереса во входной истории. Множество известных по контактам категорий обозначается K(u,T).

$$K(u,T) = \{l \in L : contact(u,l,t) = 1 \text{ для некоторого } t \in [T - 90 \text{ дней}, T)\}$$

Положительными метками становятся детальные категории, в которых пользователь совершил контакт в течение 14 дней после T и в которых у него не было контакта в предыдущие 90 дней. Если такие контакты произошли в нескольких новых категориях, все они сохраняются в целевой переменной одного примера.

$$Y(u,T) = \{l \in L \setminus K(u,T) : contact(u,l,t) = 1 \text{ для некоторого } t \in [T, T + 14 \text{ дней})\}$$

*Таблица 1 — Основные обозначения постановки задачи*

| Обозначение | Смысл |
|---|---|
| u | пользователь |
| T | момент формирования прогноза |
| H(u,T) | история событий до T |
| L | множество детальных категорий |
| K(u,T) | категории с контактом в окне новизны |
| Y(u,T) | новые категории с контактом в будущем окне |
| C(u,T) | допустимое множество кандидатов L \ K(u,T) |

## 2.4. Маска новых категорий и сохранение полной истории

Категории из K(u,T) исключаются из множества рекомендаций и из функции потерь для данного примера. При этом события, связанные с ними, не удаляются из входной истории. Например, прошлый контакт в ремонте техники может быть важен для прогноза интереса к установке или обслуживанию оборудования. Удаление такого события лишило бы модель содержательной части поведения пользователя.

Правило новизны применяется только к кандидатам и целевой переменной, но не к входной истории. Допустимое множество имеет вид C(u,T) = L \ K(u,T). Автоматические проверки должны подтверждать, что прошлые события остаются во входе, а категории с недавним контактом не участвуют ни в выдаче, ни в функции потерь.

## 2.5. Два сценария использования

В первом сценарии модель возвращает пользователю первые K новых категорий. Во втором бизнес задаёт категорию, а система ранжирует допустимых пользователей. Для второго сценария отдельно оцениваются точность, полнота и выигрыш относительно случайного отбора.

# 3. Обзор существующих подходов

## 3.1. Неперсонализированные и коллаборативные методы

Простейший метод ранжирует категории по их общей популярности. Он не использует историю конкретного пользователя, но служит обязательной проверкой: сложная модель должна превосходить частотность целевых контактов в обучающем периоде. Случайное ранжирование задаёт нижнюю границу качества.

Коллаборативная фильтрация по объектам строит рекомендации по совместной встречаемости категорий в поведении пользователей [1]. В нашей задаче категории из истории голосуют за связанные с ними новые категории, а вклад нормируется с учётом популярности. Метод легко интерпретировать, и он близок к исходной логике категорийных перетоков.

Матричная факторизация представляет пользователей и категории в общем скрытом пространстве [2]. Для неявной обратной связи можно использовать попарные функции потерь, например BPR [3]. Такие модели персонализируют выдачу и учитывают совместные закономерности, но обычно не моделируют порядок событий. Поэтому факторизация служит сильным коллаборативным базовым методом, но не заменяет последовательную архитектуру.

## 3.2. Последовательные рекомендательные системы

Последовательные модели рассматривают историю как упорядоченный набор действий. Марковская модель первого порядка оценивает вероятность следующей категории по последнему состоянию. Её преимущество состоит в простоте и устойчивости на разреженных данных, а ограничение — в невозможности учитывать дальние зависимости и несколько параллельных сценариев поведения.

GRU4Rec стал одним из первых нейросетевых подходов к рекомендации следующего объекта внутри сессии: скрытое состояние рекуррентной сети обновляется после каждого события [4]. Модель показала ценность явного учёта порядка, однако последовательная обработка затрудняет параллельное обучение, а длинная разнородная история может не помещаться в одно состояние.

SASRec использует механизм внимания с маской: при прогнозе очередного шага модель не видит более поздние события [5]. Это позволяет учитывать дальние связи в истории и обучаться параллельно. BERT4Rec, напротив, восстанавливает скрытые элементы по контексту с обеих сторон [6]. Такая цель полезна для заполнения пропусков, но хуже соответствует нашей задаче прогноза будущего только по событиям до момента T.

Обычная позиционная кодировка отражает порядок, но не фактические интервалы между событиями. TiSASRec показывает, что одинаковая последовательность при разных интервалах может требовать разных прогнозов, и добавляет временные признаки в механизм внимания [7]. Поэтому в нашей модели учитываются и позиция, и время события относительно T.

## 3.3. Несколько скрытых представлений пользователя

Большинство последовательных моделей сводит историю к одному вектору пользователя. Это упрощает расчёт оценок, но может смешивать независимые потребности. Например, один человек может одновременно интересоваться ремонтом автомобиля, образованием и организацией мероприятия; усреднение этих сигналов затрудняет поиск новых категорий.

MIND описывает пользователя несколькими скрытыми векторами и извлекает их с помощью динамической маршрутизации капсул [8]. ComiRec развивает эту идею и предлагает, в частности, вариант ComiRec-SA на основе механизма внимания [9]. Для каждого кандидата выбирается наиболее близкое скрытое представление пользователя — это соответствует ситуации, когда категория связана хотя бы с одним из поведенческих сценариев пользователя.

В работе используется общая схема ComiRec-SA, но исходная модель не воспроизводится без изменений. Объектами служат события с типом действия, временем и полным путём детальной категории; один пример может иметь несколько положительных меток, а категории с недавним контактом исключаются из кандидатов. Вариант на основе внимания выбран как более прозрачный для этой адаптации. Главным контролем служит та же модель с одним скрытым вектором пользователя.

## 3.4. Крупные промышленные модели и границы работы

Современные промышленные системы развивают генеративное моделирование длинных историй. HSTU предназначен для высококардинальных потоковых данных [10], а ARGUS показывает, как масштабировать трансформерные рекомендации до сотен миллионов и миллиарда параметров и раздельно прогнозировать следующий объект и тип обратной связи [11]. Эти работы подтверждают ценность глубокого моделирования истории, но требуют масштаба данных и инфраструктуры, который не нужен для ответа на исследовательский вопрос курсовой.

Поэтому исследование сосредоточено на контролируемой проверке гипотезы о нескольких скрытых представлениях пользователя. Вариант той же модели с $K = 1$ служит главным нейросетевым контролем, а $K > 1$ — основным методом. Так влияние числа скрытых представлений отделяется от различий в данных, признаках и условиях обучения.

*Таблица 2 — Место рассматриваемых методов в исследовании*

| Класс методов | Что учитывает | Роль в работе |
|---|---|---|
| Случайное ранжирование / популярность | случайность или общую частотность | нижняя граница и контроль популярности |
| Совместная встречаемость / ItemKNN | совместную встречаемость категорий | интерпретируемый поведенческий базовый метод |
| Марковская модель | локальный порядок переходов | теоретический простой последовательный ориентир |
| Матричная факторизация / SVD | латентные пользователь–категория связи | сильный непоследовательный базовый метод |
| SASRec | длинные последовательные зависимости | теоретический ориентир K = 1 |
| Модель на основе ComiRec-SA | несколько скрытых представлений пользователя | основная исследуемая модель |

### 3.5. Исследовательский пробел и выбор метода

Существующие работы предлагают сильные последовательные модели и способы описывать пользователя несколькими скрытыми представлениями пользователя, но не дают готового решения для нашей постановки. Здесь положительная метка означает новый контакт на полном пути таксономии, один пример может иметь несколько меток, а результат должен поддерживать два направления отбора. Поэтому сначала сравниваются базовые методы, затем варианты одной Transformer-архитектуры с одним и двумя скрытыми представлениями пользователя, после чего отдельно проверяются объём данных, длина истории и перенос результата во времени. Признаки действия и времени и максимальная длина 128 входят в основную конфигурацию; их отдельный причинный вклад не заявляется без сохранённых контролируемых сравнений.

## 4. Данные и построение обучающей выборки

### 4.1. Схема поведенческих событий

Исходные данные представляют собой журнал событий, упорядоченных по пользователю и времени. Минимальный набор полей включает user_id, timestamp, vertical, category, param1 и action_type. Идентификаторы пользователей используются для группировки истории, но не передаются модели как категориальный признак: задача должна решаться по поведению, а не за счёт запоминания пользователей.

*Таблица 3 — Поведенческие события, используемые в работе*

| Тип события | Интерпретация | Использование |
|---|---|---|
| Просмотр | слабый сигнал интереса | вход модели |
| Добавление в избранное | более сильный сигнал намерения | вход модели |
| Контакт типа 1 | первый технический тип контакта в источнике | вход и положительная метка |
| Контакт типа 2 | контакт с признаком is_valid_for_dtb=true | вход и положительная метка |

Источник содержит два технических типа контакта. Их бизнес-расшифровка в локальных артефактах не сохранена, поэтому в работе они рассматриваются только как два значения типа действия. Во входной последовательности типы различаются, а при построении целевой переменной оба считаются фактом контакта.

## 4.2. Формирование обучающих примеров

Выборка состоит не из уникальных пользователей, а из примеров «пользователь — момент T». Для одного пользователя может быть сформировано несколько примеров в разные даты, если каждый из них удовлетворяет требованиям к доступной истории и полностью наблюдаемому будущему окну. Это увеличивает число обучающих примеров и позволяет моделировать изменение интересов во времени.

Пример строится только после определения временного разбиения. Все агрегаты, словари популярности, веса совместной встречаемости и параметры нормализации рассчитываются только по доступной обучающей части. Целевое окно должно целиком находиться внутри соответствующего периода: иначе будущий контакт либо попадёт в признаки, либо останется ненаблюдаемым.

### 4.3. Сжатие повторных событий и ограничение длины

Повторные просмотры одного детальной категории могут создавать длинные последовательности, в которых один слабый сигнал доминирует только из-за частоты логирования. Поэтому однородные повторные просмотры сжимаются, а их количество сохраняется в признаке count_views. Добавления в избранное и контакты не заменяются просмотрами и имеют приоритет при сохранении событий.

После сжатия последовательность ограничивается последними M событиями. В основной конфигурации M = 128; при этом 19,51–20,16% историй всё ещё обрезаются. Отдельные сопоставимые результаты для M = 64 и M = 256 в финальном наборе

артефактов не сохранены, поэтому самостоятельный вклад максимальной длины в этой работе не оценивается.

### 4.4. Разведочный анализ данных

Разведочный анализ определил дальнейшие эксперименты. Доля примеров с целевым контактом лежит в диапазоне 19,22–20,74%, а 29,64–30,82% примеров с целевым контактом содержат несколько целевых категорий. Это подтверждает постановку с несколькими метками. При ограничении истории 128 событиями обрезается около 20% последовательностей, поэтому календарное окно и максимальное число событий нужно проверять отдельно. Распределение целевых категорий имеет длинный хвост, а его изменение во времени требует хронологической оценки.

### 4.5. Фактический состав данных

Обновлённый DWH-экстракт охватывает период с 1 августа 2025 года по 21 августа 2026 года и содержит 823 343 381 событие и 70 350 249 контактов. События принадлежат 2 595 417 пользователям, контакты — 2 027 732; объединённая аудитория насчитывает 2 616 945 пользователей. В словарь целевых категорий входят 351 детальная категория, каждый из которых задаётся полным путём vertical | category | param1.

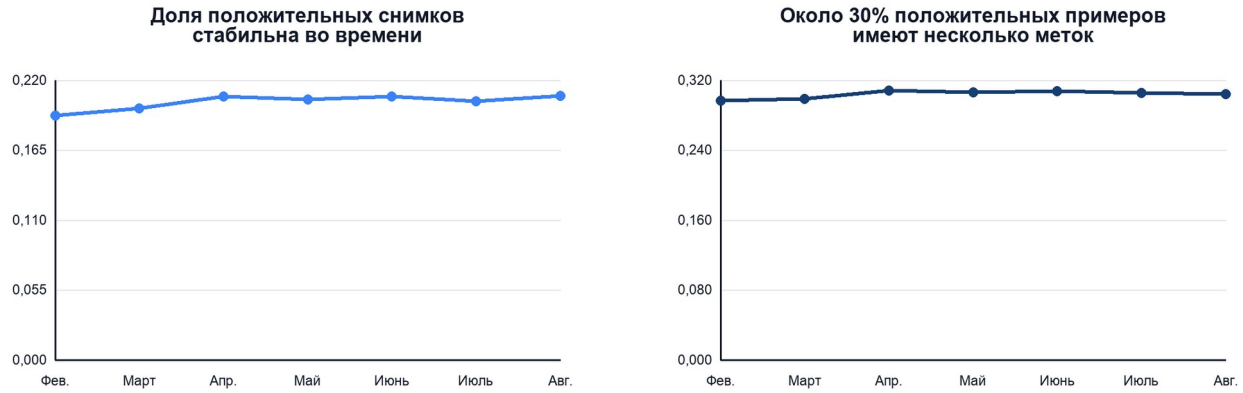



Рисунок 1 — Стабильность доли примеров с целевым контактом и примеров с несколькими метками

Экстракт строится только для событий, сопоставленных с активной таксономией. В однодневной проверке до фильтрации не сопоставились 263 231 из 9 603 566 событий (2,74%) и 8 796 из 231 050 контактов (3,81%). Поэтому офлайн-оценка относится только к направлениям с полным таксономическим путём; возможное смещение из-за несопоставленных микрокатегорий учитывается как ограничение.

Таблица 4 — Основные характеристики временных примеров

| Дата T | Примеры | Положительные | Несколько меток среди положительных | Обрезано на 128 |
|---|---|---|---|---|
| 01.02.2026 | 1 516 296 | 19,22% | 29,64% | 19,93% |
| 01.03.2026 | 1 502 143 | 19,79% | 29,85% | 19,59% |
| 01.04.2026 | 1 510 637 | 20,72% | 30,82% | 19,84% |
| 01.05.2026 | 1 530 848 | 20,49% | 30,61% | 20,16% |
| 01.06.2026 | 1 541 603 | 20,71% | 30,71% | 20,12% |
| 01.07.2026 | 1 551 597 | 20,33% | 30,57% | 19,92% |
| 01.08.2026 | 1 559 134 | 20,74% | 30,43% | 19,51% |

Доля примеров с целевым контактом стабильна и составляет 19,22–20,74%. Среди них 29,64–30,82% содержат несколько новых целевых категорий, что подтверждает постановку с несколькими метками. При M = 128 обрезается 19,51–20,16% историй. Дивергенция Йенсена — Шеннона между соседними распределениями целей лежит в диапазоне 0,0042–0,0184; наибольший сдвиг между мартом и апрелем не сопровождается резким изменением доли примеров с целевым контактом.

### 4.6. Контроль целевой переменной и утечек

Корректность выборки проверяется автоматическими инвариантами. Ни одно входное событие не должно происходить в момент T или позже; каждая положительная метка должна соответствовать контакту в течение 14 дней после T; у положительной категории не должно быть контакта в предыдущие 90 дней; все положительные категории одного примера должны сохраняться; одинаковые названия param1 в разных путях не должны получать общий идентификатор.

Отдельно проверяется, что базовые методы и признаки не используют статистики из будущего. Даже локально хронологичное разбиение может нарушать общую временную шкалу и передавать модели взаимодействия, произошедшие после тестового момента [12]. Поэтому все методы в работе оцениваются на единых глобальных временных границах.

# 5. Предлагаемая модель

## 5.1. Общая схема

Модель включает четыре части: представление событий, Transformer-энкодер истории, модуль формирования K скрытых представлений пользователя и общую голову оценки детальных категорий. Энкодер строит контекстные представления событий. Этот модуль объединяет их в K векторов, а оценка категории определяется её близостью к наиболее подходящему вектору.

История событий → контекстные представления → K скрытых векторов пользователя → оценки новых категорий

## 5.2. Представление детальной категории и события

В базовой конфигурации для каждого детальной категории обучается отдельное векторное представление. Технический идентификатор leaf_id однозначно строится из полного пути vertical | category | param1, поэтому одноимённые значения param1 из разных веток каталога не объединяются. Отдельные представления уровней vertical, category и param1 не добавлялись в подтверждённую финальную конфигурацию.

$$q(l) = Emb(leaf_id(vertical, category, param1))$$

Представление события складывается из векторов детальной категории, типа действия, позиции и дискретизированного логарифма времени от события до T. Число повторных просмотров используется при сжатии истории, но пока не передаётся отдельным числовым признаком. Его вклад вместе с отдельными уровнями таксономии оставлен для контролируемого сравнения.

$$x_i = Emb(leaf_i) + Emb(action_i) + Emb(position_i) + Emb(time_to_T_i)$$

## 5.3. Контекстный энкодер

Последовательность событий обрабатывается компактным Transformer-энкодером. Внутри 90-дневной истории внимание двунаправленное: все события уже произошли до T, поэтому их взаимное внимание не создаёт утечки будущего. Техническая маска исключает заполнители, добавленные до общей длины последовательностей.

$$H = TransformerEncoder(x_1, x_2, ..., x_m), \quad H \in R^{(m \times d)}$$

Число слоёв, размер скрытого пространства, число голов внимания и доля случайного отключения нейронов выбираются по валидационной выборке. Для K = 1 и K > 1 они одинаковы, чтобы преимущество варианта с несколькими скрытыми представлениями не объяснялось большей ёмкостью.

## 5.4. Формирование нескольких скрытых представлений пользователя

Модуль формирования нескольких скрытых представлений пользователя следует общей идее ComiRec-SA [9]. Для каждого из K скрытых представлений обучается отдельный вектор-запрос, который назначает веса событиям истории. Дополнительная нормировка заставляет запросы конкурировать за события, а итоговый скрытый вектор пользователя вычисляется как взвешенная сумма контекстных представлений.

$$r_{ki} = q_k^T h_i / (\sqrt{d} \cdot \tau), \quad A_{ki} \propto softmax_i(r_{ki}) \cdot softmax_k(r_{ki})$$

$$z_k = \Sigma_i A_{ki} h_i, \quad k = 1, \ldots, K$$

Число скрытых представлений K выбирается экспериментально из {1, 2, 4, 8}. Вариант K = 1 служит главным контролем: данные, энкодер, признаки и обучение остаются прежними, меняется только число векторов. Дополнительно измеряется их косинусное сходство. Если оно велико, несколько векторов фактически дублируют одно и то же направление поведения, даже когда метрика ранжирования не ухудшается.

## 5.5. Оценка категорий и функция потерь

Категория сопоставляется с наиболее близким скрытым вектором пользователя пользователя. При скалярном произведении оценка пары имеет вид:

$$s(u,l) = max_k \, z_k^T \, q(l)$$

Поскольку в будущем окне может быть несколько новых контактов, для каждого допустимого детальной категории вычисляется бинарная кросс-энтропия. Категории с недавним контактом маскируются и не считаются отрицательными. При 351 классе функцию потерь можно считать по всему допустимому каталогу без выборки отрицательных примеров.

$$L_{BCE}(B) = -1/|P_B| \, \Sigma_{(u,T,l) \in P_B} [50 \, y_{u,T,l} \log \sigma(s_{u,T,l}) + (1 - y_{u,T,l}) \log(1 - \sigma(s_{u,T,l}))]$$

$$L_{total} = L_{BCE} + \lambda_{att} R_{att}(A) + \lambda_{int} R_{int}(Z)$$

Здесь B — мини-батч, а P_B — множество всех пар «пример — допустимая категория» в нём, для которых candidate_mask=1. Усреднение по |P_B| соответствует операции raw[candidates].mean() в коде. Во всех сохранённых конфигурациях положительная метка получает вес 50 в бинарной кросс-энтропии; формула выше соответствует фактическому pos_weight=50 в binary_cross_entropy_with_logits. R_att — средний квадрат отклонения нормированной матрицы Грама распределений внимания A от единичной матрицы, а R_int — тот же штраф для матрицы Грама L2-нормированных скрытых

векторов пользователя Z. В финальной d128 коэффициенты λ_att и λ_int равны 0,10 и 0,10; в уменьшенных d64-экспериментах — 0,10 и 0,50. Эти значения подтверждаются config.json и кодом обучения. Отдельных запусков, где меняется только положительный вес или только один штраф, нет, поэтому самостоятельный причинный вклад этих компонентов в метрики не заявляется.

### 5.6. Контроль K = 1 и связь с SASRec

SASRec формирует одно представление последовательности и прогнозирует следующий объект [5]. У нас один пример может иметь несколько будущих меток, а категории с недавним контактом исключаются. Отдельная реализация SASRec поэтому внесла бы сразу несколько различий. Главным контролем выбран K = 1 в том же коде: сохраняются энкодер, признаки, функция потерь, данные и число эпох, меняется только число скрытых векторов пользователя. SASRec остаётся теоретическим ориентиром, но не нужен для центрального вывода о K.

## 6. Базовые методы и принципы честного сравнения

Набор базовых методов включает случайное ранжирование, популярность, совместную встречаемость и латентные коллаборативные связи. Каждый метод обучается только на доступной части временного среза и ранжирует одинаковое множество новых категорий. Нейросетевым контролем служит та же Transformer-модель с K = 1.

Таблица 5 — Базовые методы и их роль в эксперименте

| Метод | Принцип | Проверяемый вопрос |
|---|---|---|
| Случайное ранжирование | случайная перестановка кандидатов | насколько задача отличается от случайной |
| Популярность | частотность целевых контактов в обучении | достаточно ли общей популярности |
| Совместная встречаемость | связи категорий с историей пользователя | даёт ли совместная встречаемость персонализированный сигнал |
| PureSVD | матричная факторизация без порядка и времени | нужна ли последовательная модель |
| Переходы, 30-дневная адаптация | направленные связи категорий; персонализированный топ-5 | насколько воспроизводимая старая идея уступает новой модели |
| Transformer d=128, K=2 | последовательность, тип и давность действий; два представления | качество полной модели |

Для всех методов фиксируются одинаковые временные срезы, положительные метки, маска кандидатов и метрики. Гиперпараметры выбираются только по валидационной выборке, а итоговая проверочная выборка не используется для выбора архитектуры. Нейросетевые варианты получают сопоставимые размерности представлений и одинаковое число эпох при подборе.

### 6.1. Исходная модель переходов

В исходной бизнес-модели единицей анализа была направленная пара категорий A → B. По действиям пользователей за один месяц строились пары со строгим временным порядком: события не обязаны были быть соседними. Отдельно учитывались типы действий и рассчитывались условная вероятность перехода, lift, отношение рисков и потенциальный размер аудитории.

Для каждой пары вычислялись условная вероятность P(B|A), отношение к фоновой частоте B, отношение рисков μ = P(B|A) / P(B|¬A) и потенциальный размер аудитории. В исходном Excel столбцы вероятностей названы P(A|B) и P(A|~B), хотя формулы фактически считают вероятность целевой категории B при исходной категории A. В воспроизводимой реализации направление обозначено явно, а формулы сохранены.

Для единого офлайн-сравнения построена отдельная 30-дневная адаптация идеи переходов. Она использует только обучающий период, последнюю категорию пользователя как исходное направление, формирует персонализированный топ-5 и затем применяет те же целевые метки и маску кандидатов, что и остальные методы. Это воспроизводимая адаптация, а не историческая метрика бизнес-модели.

## 7. Обучение и протокол оценки

### 7.1. Временная кросс-валидация с расширяющимся окном

Случайное разбиение событий неприемлемо: модель могла бы получить сведения о поведении, которое в реальном сценарии ещё не произошло. Даже схемы с исключением последнего события могут нарушать общую хронологию и менять относительный порядок методов [12, 13]. Поэтому используется временная кросс-валидация с расширяющимся окном.

Данные разделяются хронологически. Ранние периоды используются для обучения, следующий период — для выбора эпохи, а последующий — для оценки. В дополнительных сериях вся схема сдвигается вперёд по календарю. Пользователь может встречаться в нескольких периодах, но для каждого момента T используются только события, доступные к этому моменту; целевое окно также полностью лежит после T.

Срез 0: обучение 01.02 → валидация 01.03 → проверка 01.04

Срез 1: обучение 01.02 + 01.03 → валидация 01.04 → проверка 01.05

Срез 2: обучение 01.02 + 01.03 + 01.04 → валидация 01.05 → проверка 01.06

Срез 3: обучение 01.02 + 01.03 + 01.04 + 01.05 → валидация 01.06 → проверка 01.07

Финальная схема: обучение до 01.06 включительно → валидация 01.07 → итоговая проверка 01.08

Один и тот же пользователь может присутствовать в нескольких временных периодах: это соответствует реальному сценарию повторного использования накопленной истории. Ограничение относится не к идентификатору пользователя, а ко времени: ни одно событие или агрегат после T не используется при прогнозе на T. При формировании границ учитывается и 14-дневное целевое окно, чтобы метки не пересекали недоступное будущее.

## 7.2. Метрики для сценария «пользователь → категории»

Основная метрика Recall@5 показывает, какая доля новых будущих контактных категорий пользователя попала в первые пять рекомендаций. Все значения Recall и NDCG в сравнении моделей рассчитаны на выборках пользователей, у которых в будущем окне есть хотя бы одна положительная метка. Поэтому это условное качество ранжирования среди примеров с целевым контактом, а не доля отклика во всей пользовательской популяции. Для сопоставляемых методов фиксируются одни и те же пользователи, целевые метки, маска допустимых категорий и K.

$$Recall@K(u) = |TopK(u) \cap Y(u,T)| / |Y(u,T)|$$

NDCG@5 используется как вторая ключевая метрика и учитывает позицию положительной категории в первой пятёрке: совпадение на первом месте ценнее совпадения на пятом. Recall@10 и Recall@20 показывают, как растёт полнота при расширении списка. Покрытие — доля детальных категорий, появившихся хотя бы раз в рекомендациях; оно помогает заметить концентрацию выдачи на небольшом числе популярных направлений. MAP не используется как основная метрика, поскольку частично дублирует ранговую информацию NDCG и менее прямо связана с CRM-сценарием.

Таблица 6 — Метрики персонализированного ранжирования

| Метрика | Статус | Интерпретация |
|---|---|---|
| Recall@5 | основная | доля новых целевых категорий в пяти рекомендациях |
| NDCG@5 | ключевая дополнительная | качество порядка внутри первой пятёрки |
| Recall@10 | диагностическая | полнота более широкого списка |
| Recall@20 | диагностическая | полнота при расширении списка до двадцати |

Модель выбирается по Recall@5 на валидационной выборке. Если различие невелико, дополнительно учитывается NDCG@5. Recall@10 и Recall@20 остаются диагностическими, чтобы не подстраивать решение сразу под несколько критериев.

### 7.3. Метрики для сценария «категория → пользователи»

Для заданного детальной категории модель ранжирует всех допустимых пользователей. При фиксированном размере аудитории N оцениваются Precision@N, Recall@N и Lift@N. Precision@N показывает долю пользователей из выбранной аудитории, которые совершили будущий контакт; Recall@N — долю всех будущих контактеров категории, найденных моделью. Lift@N сравнивает precision выбранной аудитории с базовой частотой контакта среди всех допустимых пользователей.

$$Lift@N(l) = Precision@N(l) / BaseRate(l)$$

Для сценария отбора аудитории вместе показываются Precision@N, Recall@N и Lift@N: один показатель без двух других может вводить в заблуждение. N задаёт размер выбранной аудитории. В работе приведены результаты для шести заранее выбранных категорий; макроусреднённые и взвешенные по частоте показатели не рассчитывались, поэтому выводы ограничены этими категориями и сохранённой июньской аудиторией.

### 7.4. План сравнений

Эксперименты разделены на самостоятельные серии. Основной результат относится к полной модели d=128, обученной на 1 985 972 пользователях. Кривая объёма данных и проверка числа скрытых представлений выполнялись на d=64, чтобы провести больше контролируемых запусков. Дополнительно d=64 и d=128 с полным объёмом данных сопоставлены на одной аудитории. Поэтому абсолютные значения объединяются только тогда, когда совпадает протокол оценки.

Таблица 7 — Конфигурации отдельных серий экспериментов

| Серия экспериментов | Подтверждённая конфигурация | Что оценивается |
|---|---|---|
| Полная модель | d=128; K=2; 331 904 параметра; 1 985 972 пользователя; 4 162 636 примеров; 12 эпох, выбрана 12-я; оценка на 100 000 пользователей | Основное качество пользователь → категории |
| Контролируемые сравнения | d=64; конкретный объём указан у результата | Число скрытых представлений и длина истории |

| Серия экспериментов | Подтверждённая конфигурация | Что оценивается |
|---|---|---|
| Масштаб данных | d=64; 200 тыс. — 2 млн пользователей; оценка на 100 000 пользователей; переход 1,2 → 2 млн повторён для инициализаций 42, 7, 123 | Влияние объёма данных |
| Категория → пользователи | d=64; 1 215 226 обучающих примеров; полная июньская аудитория 1 541 603 пользователя | Отбор аудитории для шести категорий |

Целевое окно 14 дней сохраняется фиксированным, поскольку задаётся сценарием CRM, а не является свободным гиперпараметром. Историческое окно и окно новизны не смешиваются: первое определяет доступные входные события, второе — допустимость категории для рекомендации. Если в основном дизайне оба равны 90 дням, это всё равно два разных элемента постановки.

Окна истории 90 и 180 дней сравнивались в предварительном эксперименте d=64 на 50 000 обучающих примеров и одной аудитории оценки. Из-за различной доступности длинной истории составы обучающих подвыборок совпадали на 96,5%, поэтому это не чистая абляция только длины окна. Разность Recall@5 составила +0,00045, а 95%-й доверительный интервал [−0,00326; 0,00428] включал ноль. Статистически значимого преимущества 180 дней при $\alpha = 0,05$ не обнаружено, поэтому сохранено окно 90 дней: оно соответствует правилу новизны и не увеличивает объём истории без подтверждённого выигрыша.

В проверке масштаба использовалась уменьшенная модель d=64, K=2 и 100 416 параметров. Основная кривая построена при инициализации модели 42 для 200, 400, 600, 800 тысяч, 1,2 млн, 1,6 млн и 2 млн обучающих пользователей. Число обучающих примеров выросло с 418 996 до 4 162 636. Полный объём содержит 1 985 972 уникальных пользователя и далее обозначается как 2 млн. Для ключевого сравнения 1,2 и 2 млн сохранён тот же вложенный порядок пользователей с инициализацией подвыборки 42, а обучение повторено при инициализациях модели 42, 7 и 123.

Для каждой точки заданы одинаковые правила обучения: не более 12 эпох, минимум восемь эпох и остановка после трёх проверок без улучшения. Поэтому фактическое число эпох различается, но правило остановки совпадает. Отдельная июньская аудитория используется только для выбора эпохи; итог считается на одних и тех же 100 000 пользователях июля. Парный бутстреп с 20 000 повторами оценивает разность фиксированных прогнозов, но не разброс повторного обучения.

## 7.5. Сегментный анализ и статистическая устойчивость

Средняя метрика может скрывать зависимость результата от популярности. Поэтому категории делятся по частоте целевых контактов в обучении на частые, средние и редкие; Recall@5 и NDCG@5 считаются отдельно для каждой группы. Пользователи также группируются по длине истории, чтобы оценить качество при малом и большом числе поведенческих сигналов.

Вспомогательная проверка инициализации выполнена для d=64, K=2, 200 000 обучающих примеров, восьми эпох и одной июньской аудитории. Для инициализаций 42, 7 и 123 Recall@5 равен 0,37456, 0,37685 и 0,37552; среднее — 0,37564, выборочное стандартное отклонение — 0,00115.

Временная проверка той же уменьшенной конфигурации использует четыре последовательных валидационных месяца. Recall@5 по срезам равен 0,37512, 0,38847, 0,37425 и 0,37125; среднее 0,37727, выборочное стандартное отклонение 0,00765. Это вспомогательная оценка d64 на 200 000 примеров, а не временная кросс-валидация финальной d128. Первичные файлы: artifacts/temporal_cv_refresh_2026_08/k2_train200k/fold_*/metrics.json и artifacts/data_scaling_refresh_2026_08/neural_k2/fold_3/train200k/metrics.json.

## 7.6. Итоговое сравнение методов

Итоговое сравнение выполнено на одной аудитории из 100 000 пользователей. Для всех методов совпадают пользователи, целевые категории и маски кандидатов. При этом объёмы обучения различаются: полная d=128 использует 4 162 636 обучающих примеров, PureSVD — до 768 708. Поэтому таблица сравнивает завершённые методы в доступных конфигурациях, но не является чистой абляцией архитектуры.

Таблица 8 — Итоговое качество методов на одной аудитории из 100 000 пользователей

| Метод | Recall@5 | NDCG@5 | Роль | Обучение |
|---|---|---|---|---|
| Случайное ранжирование | 0,014970 | 0,009675 | нижний ориентир | нет |
| Популярность | 0,147653 | 0,099238 | неперсонализированный ориентир | статистики train |
| Переходы, 30-дневная адаптация | 0,168512 | 0,136605 | адаптация старой идеи | 30 дней train |
| Совместная встречаемость | 0,249733 | 0,184198 | связи категорий | статистики train |
| PureSVD | 0,307383 | 0,233241 | главный классический ориентир | до 768 708 примеров |

| Метод | Recall@5 | NDCG@5 | Роль | Обучение |
|---|---|---|---|---|
| Transformer d=128, K=2 | 0,404634 | 0,313043 | полная модель | 4 162 636 примеров |

PureSVD — сильнейший классический персонализированный ориентир. Полная d=128 превысила его по Recall@5 на 0,097251; 95%-й парный бутстреп-интервал равен [0,094848; 0,099643]. По NDCG@5 разность равна 0,079801 [0,077968; 0,081640]. Оба интервала выше нуля, поэтому преимущество статистически значимо при α = 0,05. Интервалы отражают неопределённость на фиксированных прогнозах и не включают повторное обучение.

30-дневная адаптация исходной модели переходов получила Recall@5 = 0,1685. Разность полной d=128 с ней равна 0,2361 и также статистически значима. Это делает сравнение воспроизводимым, но не превращает адаптацию в ретроспективную оценку исторической бизнес-модели. Для основной d=128 выполнен один запуск с инициализацией 42; усреднение по трём инициализациям относится только к отдельной серии масштабирования d=64.

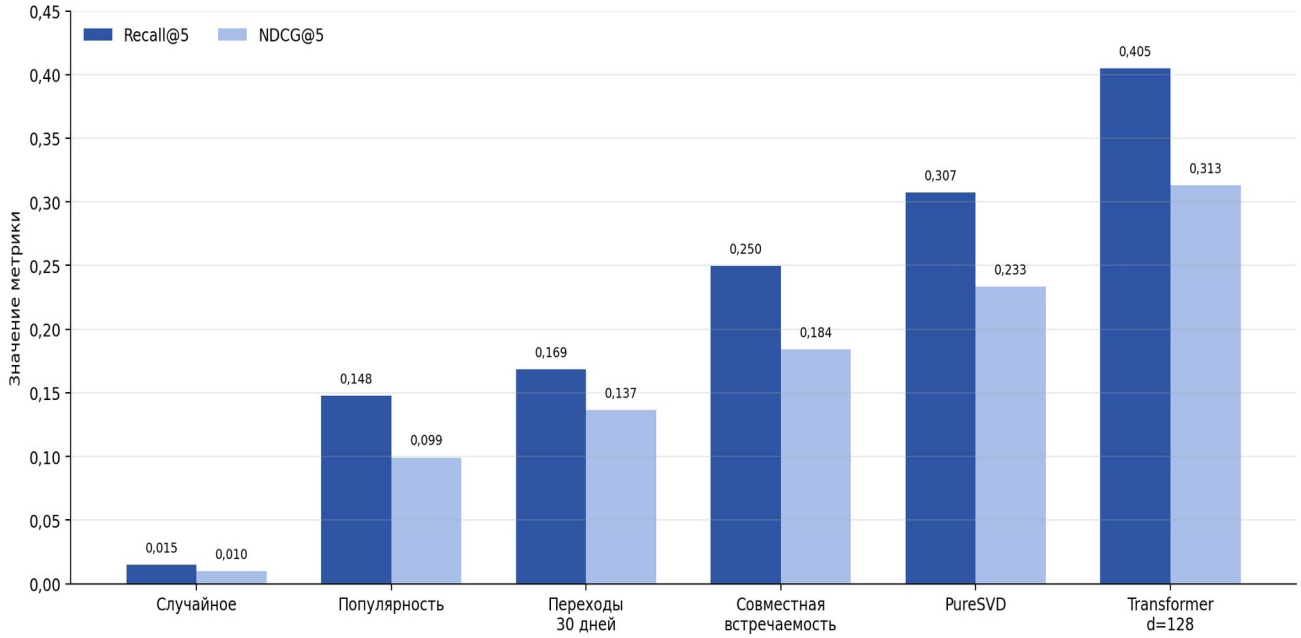



Рисунок 2 — Итоговое сравнение методов на единой аудитории из 100 000 пользователей

## 7.7. Архитектурные и вычислительные проверки

Число скрытых представлений пользователя сравнивалось в d=64 при совпадающих 400 000 обучающих примерах, инициализации и восьми эпохах. Recall@5 вырос с 0,3756 при одном представлении до 0,3871 при двух; разность 0,0115 имеет 95%-й интервал [0,0077; 0,0152] и статистически значима при α = 0,05. Этот вывод относится к d=64; отдельной абляции K для полной d=128 нет.

Таблица 9 — Подтверждённые вспомогательные эксперименты и их конфигурации

| Проверка | Сопоставимая конфигурация | Recall@5 | Вывод |
|---|---|---|---|
| Одно / два представления | d64; 400 тыс. примеров; инициализация 42; 8 эпох | 0,3756 / 0,3871 | Δ = +0,0115 [0,0077; 0,0152], значимо при α=0,05 |
| Окно 90 / 180 дней | d64; 50 тыс. примеров; одна аудитория | 0,333645 / 0,334099 | Δ = +0,000454 [−0,003258; 0,004278], незначимо |
| Инициализации для 1,2 → 2 млн | d64; инициализации 42 / 7 / 123 | +0,00385 / +0,00294 / +0,00201 | во всех трёх запусках полный пул лучше |
| Полная d64 / d128 | одни 100 тыс. пользователей; полный обучающий пул | 0,398646 / 0,404634 | d128 выше на +0,005988 [0,004390; 0,007538] |

В модели используются два регуляризатора: один уменьшает сходство распределений внимания, другой — сходство итоговых скрытых представлений пользователя. Их веса и положительный вес 50 являются частью выбранной конфигурации. Отдельных запусков, где меняется только один из этих компонентов, нет, поэтому их самостоятельный причинный вклад не заявляется.

## 7.8. Зависимость качества от числа обучающих пользователей

В эксперименте меняется число уникальных пользователей, а не число строк. Все точки используют одну уменьшенную архитектуру d=64, K=2, два слоя, четыре головы и 100 416 параметров. Точки до 1,6 млн содержат ровно заданное число пользователей; полный объём содержит 1 985 972 пользователя и в тексте обозначен как 2 млн. Основная кривая построена при инициализации модели 42, а её ключевой контраст между 1,2 и 2 млн повторён при инициализациях 7 и 123. Результат относится к d64 и не позволяет численно предсказать, как изменится финальная d128.

Таблица 10 — Качество на фиксированной июльской выборке при разном числе обучающих пользователей

| Уникальные пользователи | Примеры с целевым контактом | Эпоха | Recall@5 | NDCG@5 |
|---|---|---|---|---|
| 200 000 | 418 996 | 12 | 0,383967 | 0,294931 |
| 400 000 | 839 700 | 12 | 0,389105 | 0,299961 |
| 600 000 | 1 257 968 | 10 | 0,393580 | 0,303927 |
| 800 000 | 1 677 169 | 12 | 0,395119 | 0,305030 |
| 1 200 000 | 2 514 620 | 7 | 0,394792 | 0,304889 |
| 1 600 000 | 3 353 102 | 10 | 0,395855 | 0,305960 |
| 2 млн | 4 162 636 | 8 | 0,398646 | 0,308356 |

В основной кривой при инициализации 42 полный вариант d=64 получил Recall@5 = 0,398646 и NDCG@5 = 0,308356 — лучшие значения этой серии на единой аудитории из 100 000 пользователей. Отдельное сравнение на тех же пользователях показало, что полная d=128 достигает Recall@5 = 0,404634. Поэтому различие архитектур теперь оценивается отдельно и не смешивается с кривой объёма данных.

Таблица 11 — Парные разности между соседними точками основной кривой при инициализации 42

| Переход | Δ Recall@5 [95% ДИ] | Δ NDCG@5 [95% ДИ] | Интерпретация |
|---|---|---|---|
| 200 тыс. → 400 тыс. | +0,005138 [0,003487; 0,006797] | +0,005031 [0,003931; 0,006130] | обе метрики выросли |
| 400 тыс. → 600 тыс. | +0,004475 [0,002902; 0,006067] | +0,003966 [0,002916; 0,005038] | обе метрики выросли |
| 600 тыс. → 800 тыс. | +0,001539 [0,000010; 0,003100] | +0,001103 [0,000075; 0,002146] | небольшой прирост по обеим метрикам |
| 800 тыс. → 1,2 млн | −0,000327 [−0,001847; 0,001182] | −0,000141 [−0,001148; 0,000873] | разность неопределённа; оценки немного ниже |
| 1,2 млн → 1,6 млн | +0,001063 [−0,000426; 0,002564] | +0,001071 [0,000070; 0,002064] | Recall неопределён; NDCG вырос |
| 1,6 млн → 2 млн | +0,002791 [0,001337; 0,004265] | +0,002395 [0,001422; 0,003363] | 2 млн лучше по обеим метрикам |

В основной кривой при инициализации модели 42 качество росло на каждом шаге от 200 до 800 тысяч пользователей, хотя величина прироста уменьшалась. Переход от 800 тысяч к 1,2 млн дал небольшое снижение точечных оценок, но оба доверительных интервала включают ноль. При переходе от 1,2 к 1,6 млн интервал Recall@5 также включает ноль, тогда как NDCG@5 вырос на 0,001071 с интервалом [0,000070; 0,002064]. При переходе от 1,6 млн до 2 млн Recall@5 вырос на 0,002791 [0,001337; 0,004265], а NDCG@5 — на 0,002395 [0,001422; 0,003363]. Поэтому основная кривая не подтверждает насыщение качества на 1,2 млн пользователей.

Ключевая разность «2 млн минус 1,2 млн» положительна при всех трёх инициализациях. Для Recall@5 при инициализации 42 она равна +0,003854 [0,002384; 0,005331], при 7 — +0,002944 [0,001414; 0,004469], при 123 — +0,002009 [0,000538; 0,003516]. Для NDCG@5 соответствующие значения равны +0,003467 [0,002495; 0,004439], +0,002544 [0,001533; 0,003551] и +0,001421 [0,000439; 0,002416]. Все шесть парных 95%-х интервалов лежат выше нуля и рассчитаны по одной июльской аудитории из 100 000 пользователей с 20 000 повторов бутстрепа.

Повторный запуск для инициализации 123 завершился без нехватки памяти. Точка 1,2 млн выполнила 9 эпох и выбрала состояние после 6-й; точка 2 млн выполнила 12 эпох и выбрала состояние после 10-й. По трём инициализациям описательное среднее прироста и выборочное стандартное отклонение составляют +0,002936 ± 0,000922 для Recall@5 и +0,002477 ± 0,001024 для NDCG@5. Эти значения описывают три выполненных запуска и не являются формальным межинициализационным доверительным интервалом. Итоговый аудит и первичные интервалы сохранены в reports/data_scaling_replication_2026_10/.

## 7.9. Длина истории

В предварительном эксперименте варианты 90 и 180 дней оценивались на одной аудитории при одинаковых целях и масках. Обучающие подвыборки совпадали на 96,5%, но не были полностью идентичны. Recall@5 составил 0,333645 и 0,334099; разность +0,000454 имеет 95%-й интервал [−0,003258; 0,004278]. При α = 0,05 статистически значимого преимущества 180 дней нет; наблюдаемую разность нельзя приписать только длине истории.

Таблица 12 — Предварительное сравнение окон истории на июньской выборке

| Окно истории | Обучающих примеров | Recall@5 | Разность и 95% ДИ | Вывод |
|---|---|---|---|---|
| 90 дней | 50 000 | 0,333645 | база | основная конфигурация |
| 180 дней | 50 000 | 0,334099 | +0,000454 [−0,003258; 0,004278] | значимого преимущества нет |

Поскольку более длинная история не дала подтверждённого выигрыша, основная конфигурация использует 90 дней. Этот выбор согласован с определением новой категории и не требует хранить дополнительное прошлое без доказанной пользы.

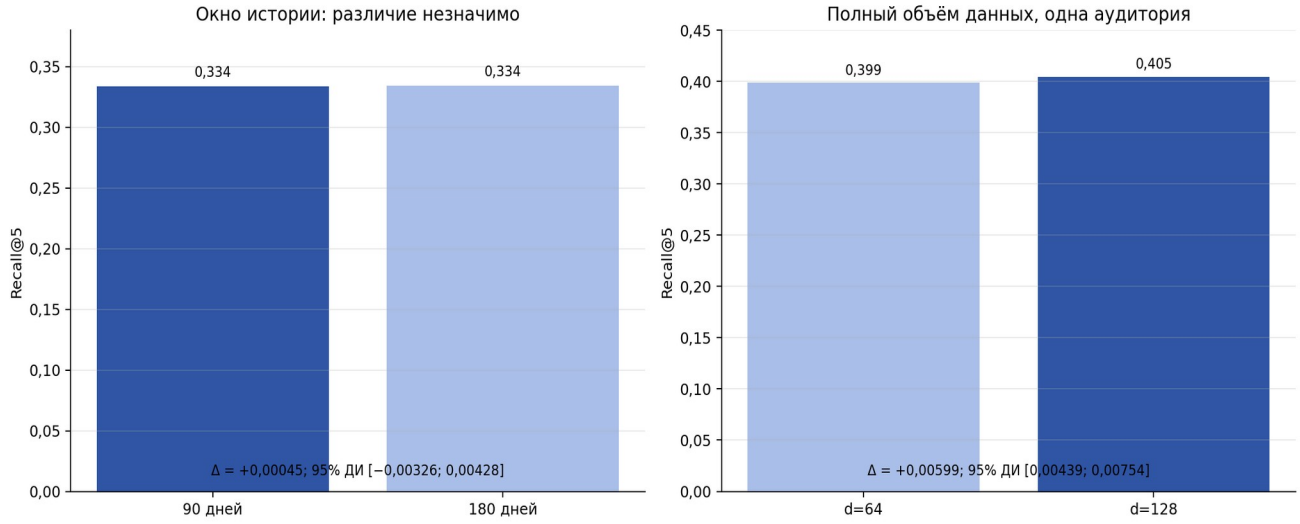



Рисунок 3 — Длина истории и сравнение полных конфигураций d=64 и d=128

## 7.10. Сегментный анализ

На итоговой аудитории из 100 000 пользователей Recall@5 равен 0,4348 для историй из 5–20 событий, 0,4443 для 21–50 и 0,3890 для 51–128. Для примеров с одной правильной категорией Recall@5 равен 0,4343, а с несколькими — 0,3370. Значит, наиболее сложны длинные последовательности и случаи, где нужно одновременно восстановить несколько направлений будущего интереса.

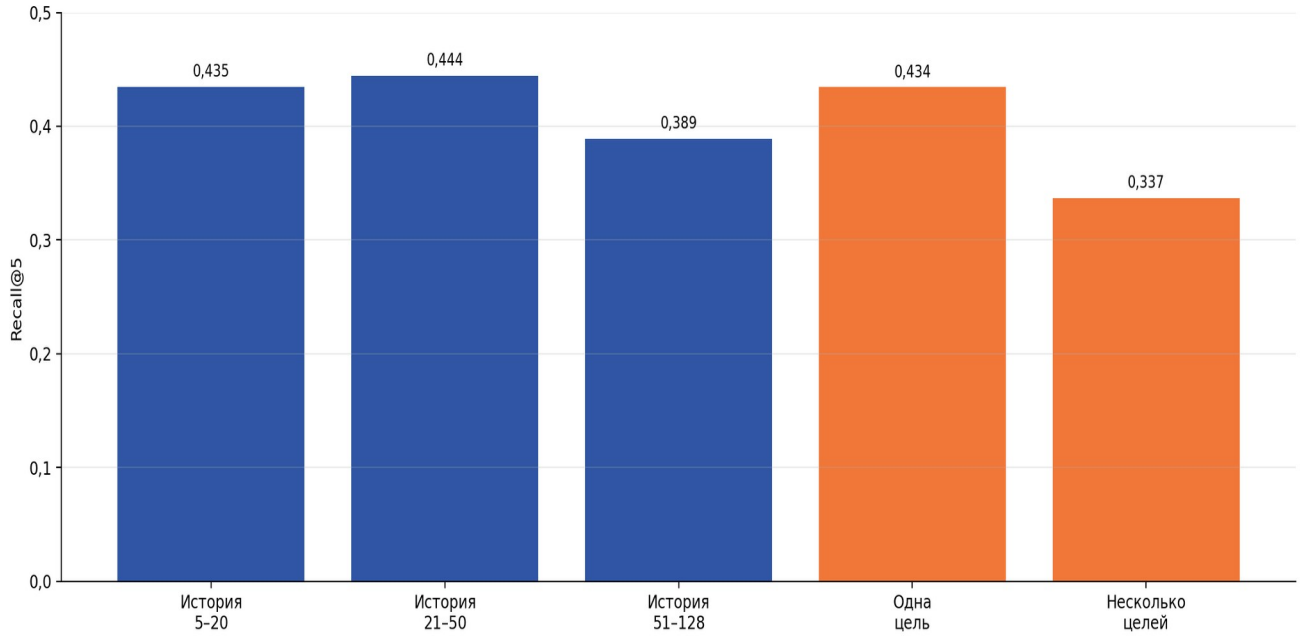



Рисунок 4 — Качество полной d=128 по длине истории и числу целевых категорий

Таблица 13 — Сегментный анализ полной d=128 на единой аудитории

| Сегмент | Число пользователей | Recall@5 | NDCG@5 |
|---|---|---|---|
| История 5–20 событий | 12 946 | 0,434794 | 0,340569 |
| История 21–50 событий | 17 518 | 0,444254 | 0,342969 |
| История 51–128 событий | 69 536 | 0,389037 | 0,300378 |
| Одна целевая категория | 69 510 | 0,434283 | 0,317415 |
| Несколько целевых категорий | 30 490 | 0,337041 | 0,303074 |

## 7.11. Сравнение полных конфигураций d=64 и d=128

Обе конфигурации обучены на полном подготовленном пуле из 1 985 972 пользователей и оценены на одних 100 000 пользователях. d=64 получила Recall@5 = 0,398646 и NDCG@5 = 0,308356; d=128 — 0,404634 и 0,313043. Разность d128 − d64 по Recall@5 равна +0,005988 [0,004390; 0,007538], по NDCG@5 — +0,004687 [0,003604; 0,005753]. Обе разности статистически значимы при α = 0,05.

Полная d=128 содержит 331 904 параметра, прошла 12 эпох и выбрала состояние после 12-й эпохи. Запуск на H100 80 GB занял 7 754 секунды, то есть 2 часа 9 минут. Линейная оценка для ускорителя, на котором выполнялась основная серия d=64, составляет около 7,1 часа; это расчётная, а не измеренная величина. Фактические времена на разных GPU нельзя использовать как чистое сравнение эффективности оборудования.

Таблица 14 — Полные конфигурации d=64 и d=128 на одной аудитории

| Конфигурация | Параметры | Обучающие данные | Recall@5 | NDCG@5 | Время |
|---|---|---|---|---|---|
| d=64, K=2 | 100 416 | 1 985 972 пользователя | 0,398646 | 0,308356 | 5 ч 30 мин на ускорителе основной серии |
| d=128, K=2 | 331 904 | 1 985 972 пользователя / 4 162 636 примеров | 0,404634 | 0,313043 | 2 ч 09 мин на H100 |

Большая конфигурация дала небольшой, но статистически значимый прирост. Компактная d=64 остаётся полезной для серий экспериментов: она требует меньше параметров и даёт близкое качество. Окончательный выбор зависит от требуемого качества, времени обучения и доступной инфраструктуры.

# 8. Практическое применение

## 8.1. Выход модели

Для актуальной истории пользователя модель вычисляет оценки всех детальных категорий. После исключения категорий с недавним контактом сохраняются псевдонимизированный идентификатор, дата расчёта, полный путь категории, оценка релевантности и место в индивидуальном списке. Оценка задаёт порядок, но не является вероятностью контакта.

Для персонализированной рекомендации категории сортируются отдельно для каждого пользователя. Для кампании по заданной категории вспомогательная d=64 отдельно проверена в обратном направлении: оценка выбранной категории рассчитана для всех допустимых пользователей, после чего пользователи отсортированы по ней. Этот вывод подтверждён для шести категорий и не переносится автоматически на весь каталог.

## 8.2. Персонализированные рекомендации

Для персонализированной коммуникации выбираются первые несколько категорий после применения правила новизны. В качестве диагностики можно сохранять события, которым механизм внимания назначил наибольший вес. Они помогают проверить здравый смысл рекомендации, но не являются причинным объяснением решения модели.

## 8.3. Аудитория заданной категории

При подготовке кампании бизнес задаёт полный путь категории и допустимый размер аудитории. В проверенном сценарии оценка этой категории

рассчитывается для всех допустимых пользователей, после чего пользователи сортируются по оценке. Затем применяются доступность канала, частотные ограничения, регион и требования к данным.

Оценка модели задаёт относительную релевантность пары «пользователь — категория», но не является вероятностью контакта или дополнительного эффекта сообщения. Пользователь мог бы совершить контакт и без CRM. Поэтому точность и lift подтверждают качество отбора аудитории, а причинный эффект коммуникации оценивается только в рандомизированном A/B-тесте.

## 8.4. Проверка сценария «категория → пользователи»

Отбор аудитории проверен на полной июньской выборке из 1 541 603 пользователей. Здесь используется не финальная d128, а отдельное сохранённое состояние модели d64, K=2: 100 416 параметров, 1 215 226 обучающих примеров, восемь эпох и инициализация 42. Для шести заранее выбранных категорий оценка сравнивалась между всеми пользователями, которым категория доступна по правилу новизны. Поэтому этот раздел подтверждает работоспособность сценария «категория → пользователи» для d64 и не переносит его значения на d128. Конфигурация и размеры аудитории сохранены в artifacts/reverse_rank_refresh_2026_08/fold_3_local_full/metadata.json.

Таблица 15 — Отбор аудитории шестью категориями на июньской выборке с моделью d64

| Категория | Доступно / с контактом | Precision@100 | Lift@100 | Recall@5000 |
|---|---|---|---|---|
| Стройматериалы | 1 425 873 / 14 192 | 0,250 | 25,12 | 0,0488 |
| Запчасти | 1 381 399 / 13 378 | 0,280 | 28,91 | 0,0520 |
| Фрукты и ягоды | 1 534 809 / 3 088 | 0,190 | 94,43 | 0,1198 |
| Окна и балконы | 1 525 599 / 2 851 | 0,090 | 48,16 | 0,1242 |
| Моторные лодки и моторы | 1 536 504 / 888 | 0,150 | 259,54 | 0,3007 |
| Электровелосипеды | 1 537 401 / 714 | 0,130 | 279,92 | 0,2703 |

У редких категорий отношение точности к базовой частоте велико именно из-за низкой базовой частоты. Поэтому в таблице рядом приведены число доступных пользователей, число будущих контактеров, Precision@100 и Recall@5000. Для «Стройматериалов» среди первых 1 000 пользователей точность составила 16,4%, полнота — 1,16%, превышение над базовой долей — 16,5 раза: будущий контакт совершили 164 пользователя. Это ретроспективная проверка вспомогательной d64, а не прогноз отклика на CRM-сообщение. Агрегированного результата по всем категориям нет; вывод ограничен шестью заранее выбранными примерами.

## 8.5. Результаты трёх CRM-экспериментов

Практическая проверка состоит из трёх CRM-кампаний. В первых двух аудиторию формировала старая агрегированная модель перетоков; статистически надёжного роста контактов и покупателей не получили. В третьей использовался

персонализированный отбор. Эта связь записана во внутренней документации проекта, но версия модели не хранится отдельным полем в карточке A/B-платформы. Кампании различались категориями, датами и содержанием сообщения, поэтому они показывают развитие решения, а не прямое сравнение старого и нового алгоритмов [14, 15].

Первая кампания шла с 17 февраля по 18 марта 2026 года и предлагала ремонт телевизоров пользователям связанной товарной категории. Поиски выросли относительно контроля на 21,5%, но контакты и покупатели не изменились статистически надёжно. Вторая кампания шла с 10 марта по 8 апреля и была посвящена ремонту мобильных устройств. Поиски выросли относительно контроля на 38,3%, число пользователей с поиском — на 52,1%, но целевые контакты и покупатели также не изменились статистически надёжно. Численность анализируемых групп первых двух кампаний в сохранённых локальных материалах отсутствует, поэтому она не восстанавливается предположением [15].

## 8.6. Результат кампании с персонализированным отбором

Третья кампания проходила с 23 апреля по 19 июня 2026 года. Пользователям из сегмента «Еда» предлагалось направление «Организация досуга и отдыха». Получателей случайно разделили на контрольную и тестовую группы; анализ охватывал примерно 113,5 тыс. пользователей, которым коммуникация могла быть показана. Относительно контроля целевые контакты выросли на 36,1%, а доля целевых покупателей — на 23,0% [15]. A/B-тест оценивает коммуникацию целиком и не отделяет вклад алгоритма от текста, предложения и времени отправки. В локальном пакете сохранены итоговые показатели из внутренней A/B-платформы, но не исходная таблица по группам, поэтому эти продуктовые величины не пересчитывались независимо.

Таблица 16 — Результаты трёх CRM A/B-тестов

| Отбор и период | Дизайн | Изменение к контролю и вывод |
|---|---|---|
| Модель переходов · ремонт телевизоров | контроль и тест | поиски +21,5%; значимого роста контактов и покупателей нет |
| Модель переходов · ремонт мобильных устройств | контроль и тест | поиски +38,3%; пользователи с поиском +52,1%; значимого роста контактов и покупателей нет |
| Персонализированный отбор · досуг и отдых | контроль и тест; около 113,5 тыс. пользователей | целевые контакты +36,1%; доля целевых покупателей +23,0% |

## 8.7. Примеры использования

### 8.7.1. Подбор категорий пользователю

Для обезличенного примера модель формирует список из пяти новых категорий и сохраняет события, на которые приходилось наибольшее внимание. Это помогает

проверить здравый смысл результата, но не является причинным объяснением. На единой аудитории из 100 000 пользователей хотя бы одна фактическая будущая категория оказалась на первом месте у 22 105 пользователей и вошла в первую пятёрку у 49 000. Аудитория условна по наличию будущего нового контакта, поэтому эти доли не равны ожидаемому отклику CRM-кампании.

#### 8.7.2. Подбор аудитории для категории

Сценарий отбора аудитории оценён отдельно на полной июньской выборке из 1 541 603 пользователей с моделью d=64. Для «Стройматериалов» среди первых 100 пользователей будущий контакт совершили 25%, тогда как базовая доля среди допустимых пользователей была около 1%. Это подтверждает работоспособность обратного ранжирования в сохранённом эксперименте, но не является оценкой причинного эффекта сообщения и ограничено шестью категориями.

#### 8.7.3. Связанные категории как дополнительный сценарий

Связанные категории рассчитываются отдельно по совместным интересам пользователей и не являются выходом нейросетевой модели. Для каждой пары полных путей считается нормированная совместная встречаемость; пары менее чем со 100 общими пользователями исключаются. Для «Ремонта и обслуживания техники» наиболее тесно связаны «Монтаж и установка техники», «Компьютерная помощь», «Оборудование, производство», «Вывоз мусора и вторсырья» и «Услуги посредников». Одинаковые названия param1 из разных веток каталога при расчёте не объединяются. Такой список помогает сформулировать более широкий сценарий коммуникации, но требует собственной оценки качества.

Обезличенные примеры, сводные показатели и проверки корректности включены в электронное приложение к работе.

### 8.8. Схема внедрения

Для практического использования нужны регулярное обновление событий, построение актуальных историй, пакетный расчёт рекомендаций и выгрузка аудиторий. Вместе с результатом должны храниться дата расчёта, версия таксономии, параметры правила новизны, версия модели и период обучения. В мониторинге следует отслеживать изменение состава действий, долю неизвестных категорий и качество на категориях разной популярности.

## 9. Ограничения и угрозы валидности

### 9.1. Ограничения целевой переменной

Контакт служит наблюдаемым признаком интереса, но не подтверждает сделку или качество полученной услуги. Отсутствие контакта также не всегда означает отсутствие

потребности: пользователь мог решить задачу вне платформы или не найти подходящее предложение.

### 9.2. Смещения наблюдаемых данных

История взаимодействий зависит от прежних алгоритмов ранжирования, доступности предложений и уже отправленных CRM-коммуникаций. Поэтому данные отражают не только предпочтения пользователей, но и решения предыдущих систем. Частые категории получают больше показов, что может усиливать разрыв в качестве между популярными и редкими направлениями.

Экстракт включает только события, сопоставленные с полным путём таксономии. В однодневной проверке до фильтрации не сопоставились 2,74% событий и 3,81% контактов. Если пропуски неодинаковы по направлениям, офлайн-оценка может быть смещена в пользу лучше размеченной части каталога. Для полной d=128 выполнен один запуск; доверительные интервалы главного сравнения относятся к фиксированным прогнозам и не измеряют разброс повторного обучения.

### 9.3. Переносимость во времени и по категориям

Каталог и поведение пользователей меняются, поэтому результат одного календарного периода не доказывает долгосрочную устойчивость. Итоговая аудитория также включает только пользователей, у которых в следующие 14 дней был новый контакт. Метрики описывают качество ранжирования при условии наличия цели и не являются прогнозом отклика во всей CRM-базе.

Кривая масштаба d=64 построена при инициализации 42, а ключевой переход 1,2 → 2 млн повторён при инициализациях 42, 7 и 123. Во всех трёх запусках прирост положителен; средний прирост Recall@5 равен +0,002936. Это описательная устойчивость эффекта в d=64. Основная d=128 обучалась один раз; её преимущество над d=64 проверено на фиксированных прогнозах, но не усреднялось по инициализациям.

### 9.4. Ограничения персонализации

Для новых пользователей и пользователей с короткой историей сложная модель может быть неустойчива; для них нужен запасной вариант на основе популярности или совместной встречаемости категорий. Длинная история также не всегда полезна, потому что старые события могут описывать уже закрытые потребности. Поэтому календарное окно и максимальное число событий проверяются отдельно.

### 9.5. Ограничения старой модели перетоков

Старая модель назначает одно направление всем пользователям исходной категории и не учитывает различия в их полных историях. Поэтому она подходит

для формирования гипотез о связях между категориями, но не для персонализированного отбора аудитории.

Разложение истории на пары теряет многокатегорийные сценарии, повторяемость и совместное влияние нескольких потребностей. Исходная бизнес-модель агрегировала действия за месяц. 30-дневная офлайн-адаптация воспроизводит её основную идею в едином протоколе, но использует упрощения: последнее исходное направление и перенос оценки на детальные категории.

Высокие значения lift и отношения рисков у редких пар не гарантируют устойчивость: их нужно показывать вместе с числом наблюдений. Повторные действия одного активного пользователя создают зависимые пары, а наблюдаемый переход между категориями не доказывает эффект CRM-сообщения. В 30-дневной офлайн-адаптации оценки, рассчитанные на уровне более крупной категории, дополнительно распределяются по детальным категориям; это отдельное допущение.

### 9.6. Приватность и ответственное применение

Модель должна использовать только данные и цели, разрешённые внутренними правилами работы с CRM-информацией. В базовую конфигурацию не входят чувствительные профильные признаки. Выгрузка для коммуникации должна содержать только необходимые поля, а частотные ограничения и возможность отказа от уведомлений применяются независимо от оценки модели.

## 10. Заключение

Построенная система по 90-дневной истории рекомендует и ранжирует новые детальные категории на горизонте 14 дней. В отличие от агрегированных переходов, она оценивает каждую пару «пользователь — категория». Те же оценки могут поддерживать как формирование списка рекомендаций, так и отбор аудитории для заранее выбранной категории.

Полная модель d=128, K=2 обучена на 1 985 972 пользователях и 4 162 636 примерах; двенадцатая эпоха стала лучшей. На единой аудитории из 100 000 пользователей она получила Recall@5 = 0,4046 и NDCG@5 = 0,3130. По Recall@5 она статистически значимо превысила PureSVD на 0,0973 [0,0948; 0,0996] и 30-дневную адаптацию модели переходов на 0,2361 при $\alpha = 0,05$.

На полном объёме d=128 статистически значимо превысила d=64: +0,0060 Recall@5 [0,0044; 0,0075]. В отдельном эксперименте d=64 два скрытых представления пользователя были лучше одного, а полный пул около 2 млн пользователей оказался лучше 1,2 млн при всех трёх инициализациях. Эти результаты поддерживают выбранную конфигурацию, но не заменяют повторов полного запуска d=128.

CRM-кампания с персонализированным отбором дала +36,1% целевых контактов и +23,0% покупателей; две кампании на переходах — только рост поиска. Офлайн-гипотеза подтверждена; продуктовый эффект требует повторной проверки.

# Список использованных источников


[1] Sarwar B., Karypis G., Konstan J., Riedl J. Item-Based Collaborative Filtering Recommendation Algorithms. Proceedings of WWW, 2001. URL: https://ra.ethz.ch/cdstore/www10/papers/519/sdm2.html

[2] Koren Y., Bell R., Volinsky C. Matrix Factorization Techniques for Recommender Systems. Computer, 42(8), 30–37, 2009. DOI: 10.1109/MC.2009.263.

[3] Rendle S., Freudenthaler C., Gantner Z., Schmidt-Thieme L. BPR: Bayesian Personalized Ranking from Implicit Feedback. Proceedings of UAI, 2009. URL: https://arxiv.org/abs/1205.2618

[4] Hidasi B., Karatzoglou A., Baltrunas L., Tikk D. Session-Based Recommendations with Recurrent Neural Networks. ICLR, 2016. URL: https://arxiv.org/abs/1511.06939

[5] Kang W.-C., McAuley J. Self-Attentive Sequential Recommendation. IEEE ICDM, 2018. URL: https://arxiv.org/abs/1808.09781

[6] Sun F., Liu J., Wu J., Pei C., Lin X., Ou W., Jiang P. BERT4Rec: Sequential Recommendation with Bidirectional Encoder Representations from Transformer. CIKM, 2019. URL: https://arxiv.org/abs/1904.06690

[7] Li J., Wang Y., McAuley J. Time Interval Aware Self-Attention for Sequential Recommendation. WSDM, 2020, 322–330. DOI: 10.1145/3336191.3371786.

[8] Li C., Liu Z., Wu M. et al. Multi-Interest Network with Dynamic Routing for Recommendation at Tmall. CIKM, 2019. URL: https://arxiv.org/abs/1904.08030

[9] Cen Y., Zhang J., Zou X., Zhou C., Yang H., Tang J. Controllable Multi-Interest Framework for Recommendation. KDD, 2020. URL: https://arxiv.org/abs/2005.09347

[10] Zhai J., Liao L., Liu X. et al. Actions Speak Louder than Words: Trillion-Parameter Sequential Transducers for Generative Recommendations. 2024. URL: https://arxiv.org/abs/2402.17152

[11] Khrylchenko K., Matveev A., Makeev S., Baikalov V. Scaling Recommender Transformers to One Billion Parameters. 2025. URL: https://arxiv.org/abs/2507.15994

[12] Ji Y., Sun A., Zhang J., Li C. A Critical Study on Data Leakage in Recommender System Offline Evaluation. 2020. URL: https://arxiv.org/abs/2010.11060

[13] Gusak D., Volodkevich A., Klenitskiy A., Vasilev A., Frolov E. Time to Split: Exploring Data Splitting Strategies for Offline Evaluation of Sequential Recommenders. RecSys, 2025. URL: https://arxiv.org/abs/2507.16289

[14] Авито. «2026-03-04 Перетоки» и «2026-03-04 Эмбеддинги для перетоков и рексистемы». Внутренняя документация проекта. URL: https://cf.avito.ru/spaces/SE/pages/813505922/2026-03-04+Перетоки; https://cf.avito.ru/spaces/SE/pages/813505994/2026-03-04+Эмбеддинги+для+перетоков+и+рексистемы (дата обращения: 04.10.2026).

[15] Авито. Отчёты CRM A/B-тестов 30590, 31190 и 33057. Внутренняя A/B-платформа. URL: https://ab.k.avito.ru/experiments/30590/overview; https://ab.k.avito.ru/experiments/31190/overview; https://ab.k.avito.ru/experiments/33057/report (дата обращения: 04.10.2026).