Текст выступления к защите курсовой

Основная часть рассчитана примерно на 13–15 минут и охватывает слайды 1–20. Слайд с QR-кодами показывается после выводов. Последний слайд с литературой используется только при вопросах комиссии.

Слайд 1. Рекомендательная система на основе поведенческих эмбеддингов

Здравствуйте. Меня зовут Полина Рощина. Моя курсовая посвящена системе, которая по истории действий пользователя рекомендует и ранжирует новые для него категории Авито. Я расскажу, почему появилась эта задача, как я подготовила данные и построила модель, с чем её сравнивала и что получилось в офлайн-проверке и CRM-кампании.

Слайд 2. Мотивация

Работа началась с продуктовой задачи «Услуг». Внешними мы называем новых покупателей, у которых первое действие на Авито произошло сразу в «Услугах». В июле–сентябре 2025 года таких покупателей было на 23% меньше, чем годом ранее, а общее число новых покупателей снизилось на 6%.

При этом большая часть новых покупателей «Услуг» уже пользовалась другими разделами Авито. Значит, один из источников роста — помочь существующим пользователям найти новую подходящую категорию внутри площадки. Для этого нужно понимать потребность конкретного человека, а не всей аудитории в среднем.

Слайд 3. Модель перетоков между категориями

До этой работы для поиска таких направлений использовалась модель перетоков. Она брала действия за один месяц и на уровне всей аудитории считала переходы между категориями.

Например, если пользователь сначала продавал товары в одной категории, а позже становился покупателем в другой, появлялась связь между этими категориями. События должны были идти в правильном временном порядке, но не обязательно подряд. Если переход встречался чаще обычного, его использовали как гипотезу для CRM-кампании.

Модель помогала находить общие направления, но не формировала индивидуальный список рекомендаций.

Слайд 4. Ограничения модели перетоков

У старого подхода было несколько ограничений. Одна рекомендация применялась ко всей аудитории исходной категории. Длинная история распадалась на отдельные пары, поэтому модель не видела общий порядок действий и несколько параллельных потребностей. Тип действия задавался заранее, а история ограничивалась одним месяцем.

В двух CRM-кампаниях вырос поиск, однако статистически значимого роста контактов и покупателей не обнаружили. Поэтому появилась задача перейти от общей связи категорий к персонализированной рекомендации.

Слайд 5. Персонализированные рекомендации и ранжирование

Новая модель описывает историю пользователя одним или несколькими обучаемыми векторами. У каждой категории также есть свой вектор. Модель сравнивает представления пользователя с представлением каждой допустимой новой категории и получает числовую оценку.

Затем категории сортируются по этой оценке, а первые позиции становятся рекомендациями. Оценка задаёт порядок, но не является вероятностью контакта. Поэтому правильнее говорить, что модель одновременно формирует рекомендации и ранжирует новые категории.

Слайд 6. Цель работы

Цель работы — по истории действий пользователя отобрать новые категории для рекомендации и использовать те же оценки для формирования CRM-аудитории.

Отсюда два сценария. В первом для конкретного пользователя выбираются категории с наиболее высокими оценками. Во втором заранее фиксируется категория, после чего все допустимые пользователи сортируются по её оценке. Второй сценарий позволяет формировать аудиторию кампании без ручного выбора пар категорий.

Слайд 7. Постановка задачи

Для каждой даты прогноза модель получает действия пользователя за предыдущие 90 дней. Правильными ответами считаются категории, в которых в следующие 14 дней произошёл контакт и в которых контакта не было в предыдущие 90 дней.

Просмотры и добавления в избранное сами по себе не делают категорию знакомой. Критерий новой категории — отсутствие недавнего контакта. Если контакты появились сразу в нескольких новых категориях, все они сохраняются как правильные ответы.

Знакомые категории исключаются из рекомендаций, но действия в них остаются в истории, поскольку могут объяснять следующую потребность. Всего модель оценивает 351 детальную категорию.

Слайд 8. Данные

Исходный журнал содержит около 823 миллионов событий, 70 миллионов контактов и 2,6 миллиона пользователей за период с августа 2025 по август 2026 года.

В историю входят поиск, добавление в избранное и два технических типа контакта. Идентификатор пользователя нужен только для объединения событий в одну историю. В модель как признак он не передаётся, поэтому модель учится на поведении, а не запоминает конкретных людей.

После подготовки полный обучающий пул содержит около 2 миллионов уникальных пользователей.

Слайд 9. Подготовка обучающих примеров

Один обучающий пример — это история пользователя на конкретную дату прогноза. Для каждой следующей даты граница сдвигается: модель снова получает 90 дней прошлого, а правильные ответы определяются по последующим 14 дням. Так один пользователь может дать несколько примеров, но в каждом используется только информация, доступная на соответствующую дату.

Повторные однотипные просмотры сокращаются, чтобы они не вытесняли остальные действия. Затем сохраняются последние 128 событий. В основное сравнение входят истории минимум из пяти событий.

Примерно в 20% примеров возникает новый будущий контакт. Примерно в 30% таких случаев правильных категорий несколько. Поэтому задача является многометочной.

Слайд 10. Разделение данных по времени

Данные разделяются хронологически. Ранние периоды используются для обучения, следующий период — для выбора лучшей эпохи, а более поздний — для итоговой оценки.

Случайное перемешивание здесь было бы некорректным: часть будущего поведения могла бы попасть в обучение и завысить качество. В дополнительных проверках вся схема сдвигается вперёд по календарю.

В итоговом сравнении все методы оцениваются на одной аудитории из 100 тысяч пользователей. Для них совпадают правильные категории и правила исключения знакомых категорий. Этот период использовался как единая тестовая аудитория всех итоговых и вспомогательных сравнений, поэтому я не называю его полностью независимым от всей последующей аналитики.

Слайд 11. Почему ComiRec-SA

Мне была нужна модель, которая учитывает порядок действий, различает тип и давность события и не смешивает всё поведение пользователя в один усреднённый вектор.

Поэтому за основу я взяла ComiRec-SA. Эта модель сначала обрабатывает последовательность Transformer-блоком, а затем формирует несколько скрытых представлений пользователя. Это полезно, когда человек одновременно, например, занимается ремонтом квартиры и выбирает автомобиль.

Исходную идею я адаптировала к своей задаче: добавила типы действий и время, несколько правильных будущих категорий и исключение категорий с недавним контактом.

Слайд 12. Архитектура модели

Каждое действие описывается четырьмя обучаемыми векторами: категории, типа действия, позиции в последовательности и давности относительно даты прогноза. Они складываются и образуют представление события.

Последовательность проходит через два слоя Transformer с четырьмя головами внимания. После этого два обучаемых запроса распределяют внимание по событиям и формируют два итоговых вектора пользователя. Это внутренние математические представления, а не два буквально интерпретируемых человеческих интереса.

У каждой из 351 категории также есть обучаемый вектор. Для категории модель вычисляет сходство с каждым вектором пользователя и берёт большее значение. После исключения знакомых категорий первые пять становятся рекомендациями.

Размерность 128 означает, что каждый такой вектор содержит 128 чисел. В модели около 332 тысяч обучаемых параметров.

Слайд 13. Обучение модели

Для каждого примера модель выдаёт 351 оценку. Категории с будущим новым контактом получают метку один, остальные допустимые категории — ноль. Поскольку правильных категорий может быть несколько, для каждой категории независимо считается бинарная кросс-энтропия. Положительный класс получает вес 50 из-за дисбаланса.

Два регуляризатора мешают двум векторам пользователя и их распределениям внимания полностью совпасть. Все эмбеддинги, Transformer и обучаемые запросы обновляются совместно с помощью AdamW.

Полный запуск прошёл все 12 заданных эпох. Лучшей стала 12-я эпоха, поэтому ранняя остановка не сработала. Основной результат относится к одной заранее зафиксированной инициализации с seed 42. Усреднение по трём инициализациям используется только в отдельном эксперименте с объёмом данных.

Слайд 14. Методы сравнения и метрики

Я сравнила модель со случайным ранжированием, общей популярностью, совместной встречаемостью и PureSVD. PureSVD — важный ориентир, потому что он уже персонализирован: он раскладывает матрицу взаимодействий на скрытые факторы пользователя и категории, а затем по их близости восстанавливает предпочтения. Но он не моделирует порядок событий, их давность и несколько частей поведения.

Отдельно я построила 30-дневную офлайн-адаптацию старой логики переходов. Она формирует персонализированный топ-5 по последней категории пользователя и оценивается на той же аудитории. Это сравнение алгоритмической идеи, а не ретроспективная метрика исторической бизнес-модели.

Основные метрики — Recall@5 и NDCG@5. Первая показывает, какую долю правильных категорий модель нашла в первой пятёрке. Вторая дополнительно учитывает их позиции. Пользователи, цели и маски кандидатов одинаковы, но объёмы обучения методов различаются: PureSVD использует до 768 708 примеров, а полная d=128 — 4 162 636. Поэтому это сравнение готовых методов, а не чистая абляция архитектуры. Кроме того, метрики считаются среди пользователей, у которых в будущем действительно был новый контакт; это не ожидаемый отклик всей CRM-базы.

Слайд 15. Основное сравнение моделей

На общей аудитории из 100 тысяч пользователей случайное ранжирование получило Recall@5 0,0150, популярность — 0,1477, адаптация модели переходов — 0,1685, совместная встречаемость — 0,2497, PureSVD — 0,3074, а Transformer, обученный на полном пуле, — 0,4046.

По NDCG@5 Transformer получил 0,3130 против 0,2332 у PureSVD. Разница Recall@5 равна 0,0973. Её 95-процентный парный доверительный интервал составляет от 0,0948 до 0,0996.

Интервал полностью выше нуля, поэтому преимущество статистически значимо при уровне значимости 0,05.

Разница с адаптацией модели переходов ещё больше: 0,2361 по Recall@5. PureSVD тоже персонализирован, поэтому результат нельзя объяснить только наличием персонализации. Корректный вывод: полная последовательная модель лучше всех завершённых ориентиров в данном протоколе. Приписывать весь выигрыш только архитектуре нельзя, потому что объёмы обучения различались.

Слайд 16. Качество и стоимость обучения

Сначала я исследовала влияние объёма данных на компактной модели размерности 64. Она содержит около 100 тысяч параметров и позволяет быстрее проводить серию запусков.

При росте обучающего пула от 200 тысяч до почти 2 миллионов пользователей Recall@5 вырос с 0,3840 до 0,3986. Рост не был строго монотонным на каждом шаге. Однако сравнение 1,2 и 2 миллионов повторялось при трёх инициализациях, и во всех трёх полный пул оказался лучше. Средний прирост составил около 0,0029.

Затем модель размерности 128 была обучена на всём пуле: 1 985 972 пользователя и 4 162 636 обучающих примера. На H100 двенадцать эпох заняли 2 часа 9 минут. Для исходного GPU расчётное время такого запуска составляет около 7,1 часа.

На одной аудитории полная модель d=128 получила Recall@5 0,4046, а полная d=64 — 0,3986. Разница 0,0060 статистически значима: 95-процентный интервал от 0,0044 до 0,0075. Большая модель даёт лучший результат, а компактная остаётся близкой по качеству и удобной для быстрых экспериментов. Фактические времена нельзя напрямую использовать для сравнения оборудования: d=64 и d=128 обучались на разных ускорителях, а 7,1 часа для исходного GPU — расчётная оценка.

Слайд 17. Дополнительные эксперименты

Отдельно я проверила три свойства модели.

В первом эксперименте сравнивались один и два итоговых вектора пользователя. На компактной модели при остальных одинаковых условиях два вектора дали прирост Recall@5 0,0115. Разница статистически значима при уровне 0,05.

Во втором эксперименте сравнивалась история за 90 и 180 дней. Recall@5 изменился с 0,3336 до 0,3341, а доверительный интервал разности включал ноль. Значимого преимущества при уровне 0,05 нет, поэтому я сохранила 90 дней: это окно совпадает с правилом новизны и не добавляет более старые события без подтверждённого выигрыша.

Наконец, я посмотрела, где модель ошибается чаще. Качество ниже на длинных историях и у пользователей с несколькими правильными будущими категориями. Эти два случая задают направления дальнейшего улучшения.

Слайд 18. Применение модели

Один набор оценок можно использовать двумя способами. В первом модель возвращает конкретному пользователю пять новых категорий с наибольшими оценками.

Во втором фиксируется категория, после чего по её оценке сортируются все допустимые пользователи. В ретроспективной проверке для «Стройматериалов» среди первых 100

пользователей будущий контакт совершили 25%, тогда как базовая доля составляла около 1%.

Это поддерживающий эксперимент на шести категориях и вспомогательной модели, поэтому его пока нельзя переносить на весь каталог.

Слайд 19. Результаты CRM-кампаний

Две кампании, построенные на старой модели перетоков, дали рост поиска на 21,5% и 38,3%. Во второй также выросло число пользователей с поиском на 52,1%. При этом статистически значимого роста контактов и покупателей не обнаружили.

Кампания на аудитории новой модели дала рост целевых контактов на 36,1% и целевых покупателей на 23,0% относительно контроля.

Эти кампании нельзя считать прямым A/B-сравнением алгоритмов: они различались категорией, временем и сообщением. Корректный вывод состоит в том, что персонализированная аудитория дала более сильный продуктовый сигнал, который нужно подтвердить повторным тестом.

Слайд 20. Выводы

Основная гипотеза получила эмпирическую поддержку. По истории действий можно персонализированно рекомендовать и ранжировать новые категории, связанные с будущим контактом.

Финальная модель обучена на полном пуле около 2 миллионов пользователей. На общей аудитории из 100 тысяч пользователей она получила Recall@5 0,4046 и статистически значимо превзошла PureSVD, а также адаптацию старой модели переходов и более простые методы.

Полная модель d=128 немного, но значимо лучше компактной d=64. При этом компактная модель подходит для более быстрых экспериментов. Оценки модели можно использовать как для рекомендаций категорий, так и для отбора CRM-аудитории.

При этом границы вывода важны: полная d=128 обучалась с одной инициализацией; статистические интервалы относятся к фиксированным прогнозам; обратное ранжирование проверено на шести категориях; CRM-кампании не были прямым сравнением алгоритмов. Спасибо за внимание. Я готова ответить на вопросы.

Слайд без номера. Код и текст работы

На слайде размещены ссылки на репозиторий с кодом и конфигурациями и на финальный текст курсовой. Перед защитой обе ссылки и QR-коды нужно проверить с телефона.

Резерв. Литература

В работе использованы классические исследования по матричной факторизации и PureSVD, последовательные модели GRU4Rec, SASRec и BERT4Rec, модель времени TiSASRec, многовекторные модели MIND и ComiRec-SA, а также работа о временном разделении данных. Полные библиографические описания приведены в тексте курсовой.